

Ben Amor Hanine

Tunis, Tunisie | hanine.benamor@insat.ucar.tn | +216 50 801 841
github.com/BenAmorHanine | linkedin.com/in/hanine-ben-amor-3604b1247/

Résumé

Étudiante ingénieure en fin de cycle à l'INSAT, expérimentée en ML classique, LLMs, RAG, vision par ordinateur et IA multimodale. Recherche un stage PFE en IA appliquée.

EXPÉRIENCE PROFESSIONNELLE

Stagiaire en IA & Data (R&D) – Yonnov'IA

Marseille, France

Août 2026 - Septembre 2026

- Développé un moteur de recommandation sémantique hybride (9 signaux + MMR) via ONNX/fastembed + pgvector (HNSW/IVFFlat), sur un pipeline scraping-to-retrieval complet.
- Optimisé le pipeline : latence $\sim 4-5s \rightarrow$ quasi-instantané, empreinte mémoire Go $\rightarrow \sim 100$ Mo (PyTorch $\rightarrow$ ONNX Runtime), avec explicabilité PCA 3D et évaluation precision@k.

Ingénieure IA (Temps Partiel) – 1MoreThing Ventures

Tunis, Tunisie

Juin 2025 – Présent

ML & Computer Vision *Juin 2026 – Présent*

- Développé et validé 20+ cas d'usage CV (détection, pose, suivi, OCR) avec pipelines d'inférence multi-étapes déployés sur NVIDIA Jetson, sous contraintes de licence et confidentialité.
- Fine-tuning de modèles de détection et classification sur datasets annotés sur mesure, atteignant 85% mAP@50.
- Déployé modèles sur carte NVIDIA SUPER JETSON.

IA, Rag, OCR

Décembre 2025 – Mai 2026

- Conçu un système RAG air-gappé sous licences ouvertes pour une archive judiciaire arabe de $\sim 1,25$ milliard de pages (Ministère de la Justice) ; benchmarké des moteurs OCR (PaddleOCR, Qari-OCR, Baseer) par type de page et niveau de qualité via CER/WER sur un corpus manuscrit sans vérité terrain.
- Implémenté un pipeline en 8 étapes (intake, audit, découpage, structuration, indexation hybride) avec retrieval hybride (dense, BM25, visuel) et reranking par cross-encoder, en utilisant Qwen pour la génération de réponses.
- Appliqué une règle stricte d'absence de réponse sans preuve via vérification des citations, abstention graduée contre les hallucinations, et une boucle de révision à la demande avec corrections persistées comme données d'entraînement.

Stagiaire en en Machine Learning — Hydatiis

Tunis, Tunisie

Juin 2025 – Août 2025

- Conception d'une plateforme de sécurité personnelle intégrant la prédiction géospatiale des risques et la détection d'anomalies comportementales.
- Développement d'un pipeline IA vocal avec Whisper, TunBERT et SpeechBrain/Pyannote pour la transcription, la classification et l'analyse émotionnelle.
- Entraînement de modèles RandomForest/XGBoost et déploiement via des microservices FastAPI avec APIs REST pour des alertes en temps réel.

Formatrice en Programmation — PIZART Training Center

Sousse, Tunisie

Juin 2024 – Présent

- Enseignement de Python, algorithmique et ML pour différents niveaux ; conception de projets pédagogiques interactifs.

Stagiaire Génie Logiciel — ITGate Group

Sousse, Tunisie

Juillet 2024

- Développement d'un système RBAC en microservices avec Node.js, MongoDB, JWT et Angular pour la gestion des rôles.

COMPÉTENCES TECHNIQUES

- **Machine Learning & Deep Learning** : PyTorch, TensorFlow, Keras, Scikit-learn, Hugging Face Transformers, AST, XGBoost, RandomForest
- **IA Générative & LLMs** : LLMs, RAG, Modèles de Diffusion, Embeddings, Prompt Engineering, Qwen, LLaMA, Abstention Graduée
- **Vision par Ordinateur** : Détection d'Objets, Classification, Estimation de Pose, Suivi d'Objets, OCR, Edge AI, YOLO, RF-DETR, Fine-tuning, Évaluation mAP
- **Spécialisations** : NLP, NLP Arabe, Document AI, OCR (PaddleOCR), Traitement Vidéo, IA Audio & Vocale (Whisper, SpeechBrain, TunBERT), IA Multimodale (ImageBind, BLIP-2)
- **Recherche Sémantique & Vector ML** : pgvector, HNSW/IVFFlat, BM25, MMR, Reranking par Cross-Encoder, Precision@k, Explicabilité (PCA)
- **MLOps & Déploiement** : Docker, FastAPI, ONNX, Prometheus, Grafana, APIs REST, NVIDIA Jetson, MQTT

- **Données & Bases de Données** : Pandas, NumPy, SQL, Spark, Kafka, HDFS, HBase, MapReduce, PostgreSQL, MySQL, MongoDB, Matplotlib/Seaborn, Power BI
- **Programmation & Outils** : Python, Java, JavaScript/TypeScript, Git, GitHub, GitLab Actions, Linux, Agile

PROJETS RÉALISÉS

Approche multimodale intelligente pour la génération automatique de formats courts (Shorts) *Publication en cours*

Pipeline de détection de moments forts combinant ImageBind, Whisper et BLIP-2 avec un mécanisme de pondération cross-modale et Attention par segment. Détection zéro-shot via transformer-based reranking sémantique sur descriptions générées, sans données labellisées.

Classification de sons respiratoires — AST & SAM Optimizer

Reproduction et amélioration d’un pipeline Transformer sur ICBHI 2017 ; introduction de Focal Loss, Mixup et évaluation patient-wise — score ICBHI 69,4%, surpassant le papier de référence dans des conditions de généralisation plus strictes.

Pipeline Big Data — Analyse de la Qualité de l’Air (Chicago Dataset)

Pipeline end-to-end : ingestion temps réel via Kafka, traitement par Spark Structured Streaming vers HDFS, analytics batch avec Java MapReduce, serving via HBase et dashboard Streamlit — déployé sous Docker.

Optimisation des Machines de Boltzmann par Recuit Quantique

Développement d’une QBM exploitant le recuit quantique pour l’entraînement dans de grands espaces de Hilbert, avec tomographie d’état quantique sur des jeux de données de référence.

FORMATION

Diplôme d’Ingénieur en Réseaux et Télécommunications 2027 | INSAT, Tunisie

Cours pertinents : Machine Learning, Deep Learning, Analyse de données, Processus stochastiques, Optimisation, Recherche opérationnelle, Business Intelligence, Big Data

Cours Préparatoire 2024 | INSAT, Tunisie

Baccalauréat en Mathématiques: Mention Très Bien 2022 | Sousse

CERTIFICATIONS

- AWS Certified AI Practitioner (AIF-C01) AWS | 2026
- Generative AI Foundations AWS | 2026
- ML Engineer Track Datacamp | 2025

ACTIVITÉS EXTRASCOLAIRES

Administrateur Système — ACM INSAT 2023–2025

- Gestion de l’infrastructure réseau pour 100+ participants lors des compétitions CodeQuest, WinterCup et DataQuest.
- Mentorat de nouveaux membres et co-organisation de la compétition Data Overflow.

LANGUES

Français | Anglais | Arabe | Allemand, Espagnol (Basique)